



שלמה ארצי

יובל שדות - יובל אלחלו - עמית קופר - גל גר - שילת אבוחצירה

תוכן עניינים

1.	תיאור היוצר ויצירתו	3
2.	שאלת המחקר	4
3.	סקירות ספרות	
1.	Stylometry וזיהוי שינויים בסגנון כתיבה	5
2.	Periodization של קורפוסים לאורך זמן	6
3.	Topic Modeling לזיהוי נושאים בטקסטים	7
4.	ייצוג סמנטי של טקסט באמצעות Embeddings	8
4.	תיאור הקורפוס והנתונים	
1.	הקורפוס והכנת הנתונים	9
2.	סטטיסטיקות הקורפוס	10
5.	מתודולוגיה	
1.	חילוץ מאפיינים סטילומטריים	13
2.	מסווגים וזיהוי נקודות מפנה	14
3.	Topic modeling	15
4.	Embeddings באמצעות DictaBERT	16
5.	Clustering וויזואליזציה	17
6.	ניתוח איכותני באמצעות LLM	18
6.	תוצאות	
1.	תוצאות המסווגים	19
2.	ניתוח סטילומטרי	21
3.	זיהוי נקודות מפנה	25
4.	Topic Modeling	27
5.	Embeddings & Clustering	28

31	6. השוואות AI לשיטות קלאסיות
32	7. דיון ומסקנות
33	8. עבודות המשך
	9. נספחים
34	1. נספח א'
39	2. נספח ב'
39	3. נספח ג'

תיאור היוצר ויצירתו

שלמה חיים ארצי (נולד ב־26 בנובמבר 1949) הוא זמר־יוצר, מלחין ופזמונאי ישראלי, הנחשב לאחד היוצרים המשפיעים והבולטים בתרבות הישראלית. את פריצתו הגדולה עשה בשנת 1970 עם זכייתו בפסטיבל הזמר והפזמון בשיר "פתאום עכשיו, פתאום היום" ("אהבתיה"). לאורך קריירה המשתרעת על פני יותר מחמישה עשורים הוציא עשרות אלבומים, זכה בפרסים רבים, ויצירתו משלבת בין חוויות אישיות לבין אירועים חברתיים ולאומיים. שיריו זכו להצלחה מסחרית רחבה, ורבים מהם הפכו לנכסי צאן ברזל במוזיקה הישראלית ולחלק בלתי נפרד מהתרבות המקומית.



הקריירה של ארצי כוללת מספר תקופות מרכזיות, שבמהלכן חל מעבר מכתיבה מוקדמת בעלת אופי מסורתי יותר לכתיבה אישית ומזוהה עם סגנון הפופ־רוק הישראלי. אלבומים כגון גבר הולך לאיבוד, דרכים, חום יולי אוגוסט, ירח ו-שניים נחשבים לאבני דרך מרכזיות בהתפתחותו האמנותית.

לצורך מחקר זה נאסף קורפוס של שירי שלמה ארצי מכל תקופות יצירתו. עבור כל שיר נשמרו מילות השיר, שנת הפרסום והאלבום שבו הופיע, במטרה לאפשר ניתוח כרונולוגי של התפתחות סגנון הכתיבה לאורך הקריירה. רשימת השירים המלאה שעליה התבסס המחקר מופיעה בנספח א'.

שאלת המחקר

מטרת המחקר היא לבחון האם ניתן לזהות באופן אוטומטי שינויים סגנוניים ביצירתו של שלמה ארצי לאורך הקריירה שלו באמצעות שיטות חישוביות לניתוח טקסט.

שאלת המחקר המרכזית היא:

האם ניתן לזהות שינויים סגנוניים משמעותיים ביצירתו של שלמה ארצי לאורך השנים באמצעות שיטות לעיבוד שפה טבעית, והאם שינויים אלו תואמים אירועים מרכזיים בקריירה המוזיקלית שלו?

מחקרים קודמים בתחום ה־Stylometry הראו כי ניתן לזהות שינויים בסגנון הכתיבה באמצעות מדדים לשוניים וסטטיסטיים. בנוסף, מחקרים בתחום חלוקת קורפוסים לתקופות (Periodization) הראו כי ניתן לזהות באופן אוטומטי מעברים בין תקופות שונות ביצירתו של יוצר.

בהתאם לכך, במחקר זה נותחו שיריו של שלמה ארצי לאורך ציר הזמן באמצעות שילוב של ניתוח סטילומטרי, Topic Modeling, ייצוגים סמנטיים (Embeddings), ניתוח אשכולות (Clustering) וניתוח איכותני באמצעות מודל שפה גדול. מטרת הניתוח הייתה לבחון כיצד מאפייני הכתיבה משתנים לאורך השנים, והאם ניתן לזהות מגמות המעידות על התפתחות סגנונית.

השערת המחקר

אנו משערים כי ניתן יהיה לזהות באמצעות ניתוח טקסטואלי שינויים סגנוניים משמעותיים ביצירתו של שלמה ארצי לאורך הקריירה, וכי חלק משינויים אלו יתאימו לתהליכים מרכזיים בהתפתחותו המקצועית והמוזיקלית. בפרט, אנו מצפים לזהות שינוי בתקופה שבין סוף שנות השבעים לתחילת שנות השמונים, שבה עבר ארצי מכתובה המושפעת משירי ארץ ישראל ומשירי משוררים לכתובה אישית יותר ולסגנון הפופ־רוק המזוהה עמו עד היום.

Stylometry וזיהוי שינויים בסגנון כתיבה

Stylometry הוא תחום העוסק בניתוח כמותי של סגנון כתיבה באמצעות מאפיינים לשוניים הניתנים למדידה. בניגוד לניתוח תוכן המתמקד במשמעות הטקסט, ניתוח סטילומטרי בוחן כיצד הטקסט נכתב, באמצעות מדדים כגון עושר אוצר מילים, אורך מילים, אורך משפטים, שימוש במילות תפקוד, סימני פיסוק ומאפיינים לשוניים נוספים.

Gomez-Adorno ואחרים (2018) הציעו גישה לזיהוי שינויים בסגנון כתיבה לאורך הקריירה של סופרים באמצעות מאפיינים סטילומטריים בלבד. במחקר נבחנו 63 רומנים של שבעה סופרים דוברי אנגלית, כאשר עבור כל סופר חולקה הקריירה לשלוש תקופות כרונולוגיות: מוקדמת, ביניים ומאוחרת. כל תקופה יוצגה על ידי שלושה רומנים שנבחרו בהתאם לשנת הפרסום שלהם.

החוקרים חילצו שלוש קבוצות עיקריות של מאפיינים סטילומטריים: מאפייני מבנה וסגנון (כגון עושר לקסיקלי, אורך מילים, אורך משפטים ואורך פסקאות), מאפייני פיסוק (כגון פסיקים, נקודתיים, מקפים וסימני קריאה) ומאפייני שימוש במילות תפקוד. לאחר חילוץ המאפיינים ייצגו החוקרים כל יצירה כוקטור מספרי והפעילו מסווגים מסוג Logistic Regression ו-SVM במטרה לזהות לאיזו תקופת כתיבה שייכת כל יצירה.

תוצאות המחקר הראו כי עבור רוב הסופרים ניתן היה לזהות את תקופת הכתיבה בדיוק גבוה משמעותית מניחוש אקראי. השילוב של כלל המאפיינים הסטילומטריים הניב את הביצועים הטובים ביותר, ובחלק מהמקרים הושג דיוק של יותר מ-80% בזיהוי תקופת הכתיבה. החוקרים הסיקו כי סגנון כתיבה משתנה לאורך השנים באופן שניתן למדידה ולזיהוי אוטומטי באמצעות כלים חישוביים.

מחקר זה מהווה בסיס ישיר למחקר הנוכחי. בדומה לעבודתם של Gomez-Adorno ואחרים, גם במחקר זה נבחנת האפשרות לזהות שינויים סגנוניים לאורך הקריירה של יוצר יחיד. עם זאת, בעוד שהמחקר המקורי התבסס על רומנים בשפה האנגלית ועל מאפיינים סטילומטריים מסורתיים בלבד, המחקר הנוכחי משלב בנוסף שיטות מודרניות המבוססות על מודלי שפה, Embedding וניתוח סמנטי של טקסטים.

Gómez-Adorno, H., Sidorov, G., Batyrshin, I., Gelbukh, A., & Pardo, F. M. R. (2018) Automatic Detection of Diachronic Linguistic Changes in Literary Texts. Journal of Intelligent & Fuzzy Systems, 34(5), 3307–3317

Periodization של קורפוסים לאורך זמן

מחקרים רבים בתחום ניתוח הטקסטים עוסקים בזיהוי שינויים סגנוניים או נושאים לאורך זמן. אחת הבעיות המרכזיות בתחום היא קביעת גבולות בין תקופות שונות בתוך קורפוס כרונולוגי, באופן שאינו מסתמך רק על חלוקה שרירותית לשנים או לעשורים.

Alsudias ו-Tchalian (2016) הציעו מסגרת אוטומטית בשם CorPerds לביצוע Corpus Periodization - תהליך של חלוקת קורפוס טקסטואלי מסודר כרונולוגית לתקופות מובחנות. החוקרים טענו כי חלוקה ידנית לתקופות מבוססת לעיתים על שיקול דעת סובייקטיבי, ולכן יש צורך בשיטה חישובית ועקבית יותר.

השיטה שהוצעה משלבת מידע כרונולוגי עם ניתוח לשוני של הטקסטים, במטרה לזהות באופן אוטומטי נקודות מעבר משמעותיות לאורך זמן. החוקרים יישמו את השיטה על קורפוס של 4,821 כתבות עיתונות שעסקו בנושא ממשל תאגידי בין השנים 1977–2004, והצליחו לצמצם חלוקה ראשונית של 28 שנים לשבע תקופות מרכזיות בלבד.

ממצא מרכזי של המחקר היה שניתן לזהות תקופות מובחנות ונקודות מעבר משמעותיות בתוך קורפוס טקסטואלי ללא צורך בהגדרה ידנית של גבולות התקופות מראש. החוקרים הציעו כי שיטה זו מתאימה לחקר התפתחות של רעיונות, נושאים וסגנונות כתיבה לאורך זמן.

מחקר זה רלוונטי במיוחד לעבודה הנוכחית, שכן אחת ממטרות המחקר היא לזהות נקודות מפנה ביצירתו של שלמה ארצי לאורך הקריירה שלו. בדומה למחקר של Alsudais ו-Tchalian, גם כאן נעשה ניסיון לזהות תקופות מובחנות באמצעות ניתוח חישובי של הטקסטים ולא רק באמצעות חלוקה כרונולוגית ידנית.

Alsudais, A., & Tchalian, H. (2016). Corpus Periodization Framework to Periodize a Temporally Ordered Text Corpus. Proceedings of the Twenty-Second Americas Conference on Information Systems (AMCIS 2016)

Topic Modeling לזיהוי נושאים בטקסטים

Blei, Ng, ו-Jordan (2003) הציגו את מודל Latent Dirichlet Allocation (LDA), אחת השיטות הנפוצות ביותר לזיהוי נושאים (Topic Modeling) בקורפוסים טקסטואליים. מטרת המודל היא לגלות באופן אוטומטי נושאים סמויים בתוך אוסף מסמכים, ללא צורך בתיוג ידני מראש.

המודל מניח שכל מסמך מורכב משילוב של מספר נושאים, כאשר כל נושא מיוצג באמצעות התפלגות הסתברויות על מילים. לדוגמה, מסמך מסוים עשוי להיות מורכב מ-60% נושא של אהבה, 30% נושא של זיכרון ו-10% נושא של טבע. באמצעות ניתוח שכיחות המילים והקשרים ביניהן, המודל מסוגל לזהות קבוצות מילים הנוטות להופיע יחד ולהגדירן כנושאים משותפים.

במחקרם הראו החוקרים כי ניתן ליישם את השיטה על קורפוסים גדולים ולזהות מבנים נושאיים שאינם גלויים לעין בקריאה ידנית של הטקסטים. מאז פרסומו הפך מודל LDA לאחת השיטות המרכזיות בתחום כריית הטקסטים וניתוח מסמכים.

מחקר זה רלוונטי במיוחד לעבודה הנוכחית, שכן גם כאן נעשה שימוש במודל LDA לצורך זיהוי נושאים מרכזיים בשיריו של שלמה ארצי. בדומה למאמר, כל שיר יוצג כהתפלגות על פני מספר נושאים, ולאחר מכן נבחן כיצד שכיחותם של הנושאים משתנה לאורך השנים והאלבומים. מוויים בתוך אוסף מסמכים, ללא צורך בתיוג ידני מראש.

ייצוג סמנטי של טקסט באמצעות Embeddings

בשנים האחרונות הפכו ייצוגים וקטוריים של טקסט (Embeddings) לכלי מרכזי בניתוח שפה טבעית. בניגוד לגישות מסורתיות המבוססות על ספירת מילים או מאפיינים ידניים, Embeddings מאפשרים לייצג טקסטים כווקטורים מספריים הלוכדים מידע סמנטי ולשוני מורכב.

Reimers ו-Gurevych (2019) הציגו את מודל SBERT - Sentence-BERT אשר פותח לצורך יצירת ייצוגים סמנטיים של משפטים וטקסטים קצרים. המודל מבוסס על BERT אך מותאם במיוחד לשימוש של חישוב דמיון בין טקסטים, אשכול (Clustering) וחיפוש סמנטי. החוקרים הראו כי ניתן לייצג טקסטים באמצעות וקטורים צפופים במרחב רב-ממדי, כך שטקסטים בעלי משמעות דומה ימוקמו קרוב זה לזה.

במחקרם הודגם כי שימוש ב-Embeddings מאפשר לזהות קשרים סמנטיים בין טקסטים גם כאשר אינם חולקים מילים משותפות רבות. יכולת זו הופכת את הגישה למתאימה במיוחד לניתוח סגנון כתיבה ולזיהוי קבוצות טבעיות של מסמכים באמצעות שיטות אשכול.

החוקרים הראו כי שילוב של Embeddings עם אלגוריתמי Clustering מאפשר לזהות מבנים פנימיים בקורפוסים גדולים ולחשוף קבוצות טקסטים בעלות מאפיינים דומים. גישה זו נמצאה יעילה במיוחד כאשר המטרה היא לגלות דפוסים ללא שימוש בתוויות ידועות מראש.

מחקר זה רלוונטי במיוחד לעבודה הנוכחית, שכן גם כאן נעשה שימוש בייצוגים סמנטיים המבוססים על מודל שפה עברי (DictaBERT). ה-Embeddings שחולצו עבור שירי שלמה ארצי שימשו כבסיס לניתוח Clustering ולבחינת האפשרות לזהות תקופות שונות ביצירתו ללא שימוש ישיר בשנת הפרסום של השירים.

הקורפוס והכנת הנתונים

איסוף הקורפוס - קורפוס המחקר נבנה מתוך שיריו של שלמה ארצי במטרה לאפשר

ניתוח כרונולוגי של התפתחות סגנון הכתיבה לאורך הקריירה שלו. הקורפוס כולל 176 שירים שנאספו מתוך 14 אלבומים שיצאו בין השנים 1970–2025. עבור כל שיר נשמרו מילות השיר, שנת הפרסום, שם האלבום ומזהה ייחודי לצורך עיבוד וניתוח אוטומטי.


מבנה הנתונים - כל שיר נשמר כקובץ טקסט נפרד. בנוסף, נבנה קובץ

מטא-דאטה המכיל מידע על כל שיר, לרבות שנת הפרסום, שם האלבום ומזהה ייחודי. בשלב בניית הקורפוס אוחדו כלל קובצי השירים ומידע המטא-דאטה לקובץ נתונים אחיד (corpus.csv), אשר שימש כבסיס לכל הניתוחים שבוצעו במחקר. מבנה זה אפשר לבצע השוואות בין תקופות שונות בקריירה של היוצר, תוך שמירה על הקשר בין כל שיר לבין שנת פרסומו והאלבום שבו הופיע.

ניקוי והכנת הנתונים - לפני ביצוע הניתוחים בוצע תהליך ניקוי ונרמול של

הקורפוס במטרה להסיר רעשים (Noise) ולהבטיח אחידות בין כלל השירים. התהליך כלל איתור ותיקון של תווי קידוד חריגים, הסרת רווחים מיותרים, איחוד רצפי רווחים ושורות ריקות ויצירת ייצוג אחיד של הטקסט העברי. בנוסף, נשמרו עבור כל שיר הן הגרסה המקורית והן הגרסה המנוקה, לצד המטא-דאטה הרלוונטי, הכולל את שם השיר, שנת הפרסום, שם האלבום ומזהה ייחודי.

בסיום התהליך התקבל קורפוס נקי ואחיד, אשר שימש כבסיס לכל הניתוחים הסטטיסטיים, הסטילומטריים והסמנטיים שבוצעו במסגרת המחקר.




סטטיסטיקות הקורפוס

סטטיסטיקות כלליות :

ממד	ערך
מספר שירים	176
מספר אלבומים	14
סה"כ מילים	32,867
טווח השנים	1970-2025
מספר שנות פעילות בקורפוס	55
אורך שיר ממוצע (במילים)	187
אורך שיר מינימלי (במילים)	66
אורך שיר מקסימלי (במילים)	382

איור 1 : התפלגות מספר השירים בכל אלבום



- איור 1 מציג את התפלגות מספר השירים בכל אחד מאלבומי הקורפוס. ניתן לראות כי מספר השירים שנכללו מכל אלבום אינו אחיד, שכן חלק מהאלבומים מיוצגים במספר גדול יותר של שירים. הבדל זה משקף את מבנה הקורפוס שנאסף ועשוי להשפיע במידה מסוימת על הניתוחים הסטטיסטיים.

איור 2 : אורך שיר ממוצע בכל אלבום (במילים)

<u>אלבום</u>	<u>אורך ממוצע במילים</u>
שלמה ארצי	120.25
את ואני	101.90
משחקי 26	138.00
גבר הולך לאיבוד	105.88
דרכים	129.63
תרקוד	195.0
חום יולי אוגוסט	176.07
ירח	131.75
שניים	165.84
צימאון	167.13
שפויים	173.33
אושר אקספרס	171.92
קצפת	171.07
אותיות נחמה	164.13

- טבלה 2 מציגה את אורך השיר הממוצע בכל אחד מן האלבומים שנכללו בקורפוס. ניתן לראות שקיימת שונות בין האלבומים, המעידה על הבדלים במבנה השירים לאורך הקריירה.

עושר לקסיקלי - חישוב TTR (Type-Token Ratio) -

- מספר שירים – 176
- מספר מילים כולל – 32,867
- מספר מילים ייחודיות - 8,814
- **$TTR = 0.268$**

באופן כללי, הנתונים מצביעים על כך שהקורפוס מגוון הן מבחינת היקף השירים בכל אלבום והן מבחינת אורכם. שונות זו מחזקת את הצורך בניתוחים סטילומטריים וסמנטיים לבחינת השינויים בסגנון הכתיבה לאורך הקריירה של שלמה ארצי.

מתודולוגיה - חילוץ מאפיינים סטילומטריים

בשלב זה חולצו מכל שיר מאפיינים סטילומטריים, במטרה לייצג את סגנונו הלשוני של ארצי באופן כמותי. חילוץ המאפיינים התבסס על הקורפוס המעובד ועל הניתוח המורפולוגי של כל שיר, אשר כלל מידע על חלקי הדיבר (Part-of-Speech), למות (Lemmas) וצורת המילה.

המאפיינים שנחלקו לכל שיר השתייכו לארבע קבוצות עיקריות -

- **מאפיינים לקסיקליים** - חושבו מדדי עושר לשוני, ובהם יחס המילים הייחודיות TTR (Type-Token Ratio), מדד MTLD לעושר לקסיקלי, גודל אוצר המילים, אורך מילה ממוצע ואורך שורה ממוצע.
- **מאפיינים תחביריים** - חושבו היחסים היחסיים של חלקי דיבר מרכזיים, ובהם שמות עצם, פעלים, שמות תואר, תוארי הפועל, כינויי גוף, מילות יחס, מילות קישור מתאמות ומילות קישור משעבדות. בנוסף חושבו יחס פעלים לשמות עצם (Verb-Noun Ratio), שיעור מילות התפקוד (Function Word Ratio) ושיעור השימוש בגוף ראשון.
- **מאפיינים מבניים** - חושבו מספר השורות, מספר הבתים בכל שיר ושיעור החזרות (Repetition Rate), אשר נמדד באמצעות זיהוי שורות זהות החוזרות יותר מפעם אחת.
- **מאפייני אוצר מילים** - חושבו מספר הלמות הייחודיות בכל שיר, במטרה להעריך את גודל אוצר המילים ללא תלות בהטיות דקדוקיות.

לבסוף אוחדו כלל המאפיינים לטבלת מאפיינים אחת (features.csv), שבה כל שורה מייצגת שיר וכל עמודה מייצגת מאפיין סטילומטרי. טבלה זו שימשה בהמשך לניתוח ההבדלים בין התקופות, לבניית מודלי הסיווג ולשלבי האשכול (Clustering).

לציון כי לפני חישוב המאפיינים הוסרו סימני פיסוק וסימנים שאינם לשוניים, כך שכל המדדים חושבו על בסיס הטוקנים הלשוניים בלבד.

מתודולוגיה - מסווגים וזיהוי נקודות מפנה

מסווגים

לצורך בחינת יכולתם של המאפיינים הסטילומטריים להבחין בין תקופות היצירה של שלמה ארצי, נבנו מודלים של למידת מכונה לסיווג השירים לשלוש תקופות: מוקדמת, ביניים ומאוחרת. כל שיר יוצג באמצעות וקטור המאפיינים הסטילומטריים שחולץ בשלב הקודם, כאשר תווית היעד הייתה התקופה שאלה השתייך השיר.

נבחנו ארבעה מסווגים נפוצים -

- Logistic Regression
- Support Vector Machine (SVM)
- Random Forest
- k-Nearest Neighbors (k-NN)

לפני אימון המודלים בוצעה סטנדרטיזציה (Standardization) של כלל המאפיינים באמצעות StandardScaler, כדי למנוע הבדלים הנובעים מסולמות מדידה שונים.

הערכת ביצועי המסווגים בוצעה באמצעות Stratified 5-Fold Cross Validation, כך שבכל קיפול נשמר היחס בין שלוש התקופות. ביצועי המודלים הוערכו באמצעות מדד Accuracy ודווחו כממוצע וסטיתית התקן על פני כל הקיפולים.

זיהוי נקודות מפנה

בנוסף למשימת הסיווג, בוצע ניתוח שמטרתו לזהות שינויים משמעותיים בסגנון הכתיבה לאורך הקריירה של שלמה ארצי.

לשם כך חושב תחילה וקטור המאפיינים הממוצע עבור כל אלבום. לאחר מכן בוצעה סטנדרטיזציה של המאפיינים, וחושב **דמיון קוסינוס (Cosine Similarity)** בין חלונות עוקבים של אלבומים באמצעות גישת Sliding Window, עבור כל מיקום חושב הדמיון בין קבוצת האלבומים שקדמה לנקודה לבין קבוצת האלבומים שאחריה.

ערכי הדמיון שהתקבלו שימשו למדידת מידת השינוי הסגנוני לאורך הזמן. שנים שבהן התקבל דמיון נמוך באופן חריג סומנו כמועמדות לנקודות מפנה, בהתאם לסף שחושב מתוך התפלגות ערכי הדמיון.

מתודולוגיה - Topic Modeling

לצורך זיהוי אוטומטי של נושאים מרכזיים החוזרים בשירי שלמה ארצי נעשה שימוש במודל LDA (Latent Dirichlet Allocation). שיטה זו מאפשרת לזהות באופן לא־מונחה קבוצות של מילים הנוטות להופיע יחד בטקסטים, ובכך לזהות נושאים סמויים המאפיינים את הקורפוס.

בשלב הראשון נטען קובץ הקורפוס המאוחד, הכולל עבור כל שיר את הטקסט המנוקה ואת פרטי המטא־דאטה שלו, כגון מזהה השיר, שם השיר, שנת הפרסום והאלבום. לאחר מכן בוצעה טוקניזציה לטקסטים בעברית באמצעות ביטוי רגולרי, שחילץ רצפים של אותיות עבריות בלבד. כחלק מהעיבוד המקדים הוסרו מילים באורך תו אחד ומילות עצירה נפוצות בעברית, כגון מילות יחס, כינויי גוף ומילים כלליות שאינן תורמות באופן משמעותי לזיהוי הנושאים.

לאחר שלב העיבוד המקדים נבנה מילון מילים באמצעות ספריית Gensim, ולאחר מכן הוסרו ממנו מילים נדירות מדי שהופיעו בפחות משני שירים, וכן מילים נפוצות מדי שהופיעו ביותר מ־60% מן השירים. מטרת הסינון הייתה להפחית רעש ולשפר את איכות הנושאים שזוהו על ידי המודל.

בהמשך הומר כל שיר לייצוג Bag-of-Words, ולאחר מכן אומן מודל LDA באמצעות הספרייה Gensim. מספר הנושאים הוגדר כ־10, המודל אומן במשך 20 מעברים על הקורפוס (passes=20), ונעשה שימוש ב־random_state=42 לצורך שחזור התוצאות. לאחר האימון חולצו עבור כל נושא עשר המילים בעלות ההסתברות הגבוהה ביותר, ועל בסיסן הוצמדה לכל נושא תווית פרשנית.

לבסוף חושבה עבור כל שיר התפלגות הסתברויות על פני עשרת הנושאים. כלומר, כל שיר יוצג באמצעות וקטור הסתברויות, שבו כל רכיב מייצג את מידת השייכות של השיר לאחד מעשרת הנושאים. תוצאות אלו נשמרו בקובצי פלט ייעודיים: קובץ topics.csv הכולל את המילים המרכזיות בכל נושא, קובץ song_topics.csv הכולל את התפלגות הנושאים עבור כל שיר, וכן מודל ה־LDA המאומן, שנשמר כקובץ לשימוש חוזר בשלבי הניתוח המאוחרים.

מתודולוגיה - Embeddings באמצעות DictaBERT

לצורך ייצוג סמנטי של השירים נעשה שימוש במודל השפה העברי DictaBERT, המאפשר להמיר כל שיר לייצוג וקטורי צפוף הלוכד מידע לשוני וסמנטי מתוך הטקסט.

תחילה נטען קובץ הקורפוס המאוחד, ומתוכו נעשה שימוש בעמודת הטקסט המנוקה של כל שיר. עבור כל שיר בוצעה טוקניזציה באמצעות ה־Tokenizer של המודל dicta-il/dictabert. כל שיר הוגבל לאורך מרבי של 512 טוקנים, בהתאם למגבלת הקלט של המודל. טקסטים ארוכים יותר קוצרו באופן אוטומטי.

לאחר מכן הועבר כל שיר דרך מודל DictaBERT במצב הערכה (evaluation mode), ללא חישוב גרדיאנטים, מאחר שהמודל שימש לצורך חילוץ ייצוגים בלבד ולא לצורך אימון נוסף. מתוך פלט המודל נלקחו ה־last hidden states, כלומר הייצוגים הווקטוריים של כל הטוקנים בשיר. כדי לקבל וקטור יחיד עבור כל שיר, בוצע Mean Pooling על ייצוגי הטוקנים, תוך שימוש ב־attention mask כדי להתעלם מטוקני padding.

התוצאה הסופית של שלב זה היא מטריצת embeddings, שבה כל שורה מייצגת שיר אחד וכל עמודה מייצגת ממד אחד מתוך הייצוג הווקטורי שהפיק המודל. המטריצה נשמרה בקובץ embeddings.npy ושימשה בהמשך כקלט לשלבי האשכול (Clustering) והוויזואליזציה.

מתודולוגיה - Clustering וויזואליזציה

לאחר יצירת ה-embeddings עבור כלל השירים, בוצע ניתוח אשכולות (Clustering) במטרה לבדוק האם ניתן לזהות קבוצות טבעיות של שירים על סמך הייצוג הווקטורי שלהם, ללא שימוש ישיר בתוויות התקופה במהלך יצירת הקבוצות.

בשלב הראשון נטענו מטריצת ה-embeddings וקובץ הקורפוס המאוחד. לצורך ויזואליזציה של הווקטורים, שכל אחד מהם מיוצג במרחב רב-ממדי, בוצעה הפחתת ממדים באמצעות PCA לשני ממדים. כך התקבל ייצוג דו-ממדי של כל שיר, המאפשר להציג את השירים כנקודות במישור.

לאחר מכן, הופעל אלגוריתם K-Means עם $k = 3$, בהתאם לחלוקת המחקר לשלוש תקופות: מוקדמת, ביניים ומאוחרת. האשכולות חושבו על בסיס וקטורי ה-embeddings המקוריים, ולא על הייצוג הדו-ממדי שהתקבל לאחר הפחתת הממדים, כדי לשמר את מלוא המידע הסמנטי. לאחר קביעת האשכולות שויך כל שיר לאחד האשכולות, ונשמר מספר האשכול שאליו השתייך.

כדי להעריך את איכות החלוקה לאשכולות חושב מדד Silhouette Score, הבוחן את מידת הדמיון של כל שיר לשירים באותו אשכול ביחס לדמיונו לשירים באשכולות אחרים. ערך גבוה יותר של המדד מעיד על חלוקה איכותית ומופרדת יותר של האשכולות.

תוצאות שלב זה נשמרו בקובץ song_clusters.csv, הכולל עבור כל שיר את מזהה השיר, שם השיר, שנת הפרסום, האלבום, מספר האשכול וקואורדינטות ה-PCA. בנוסף הופקו שני גרפי PCA: הראשון מציג את השירים כשהם צבועים לפי האשכול שאליו שויכו, והשני מציג אותם כשהם צבועים לפי שנת הפרסום. גרפים אלה שימשו לבחינת הקשר בין האשכולות לבין התפתחות הקריירה לאורך הזמן.

מתודולוגיה - ניתוח איכותני באמצעות LLM

בנוסף לניתוחים הכמותיים, בוצע ניתוח איכותני באמצעות מודל שפה גדול, במטרה לקבל תיאור פרשני של מאפייני הסגנון בכל אחת מתקופות הקריירה המרכזיות של שלמה ארצי. שלב זה נועד להשלים את הניתוחים הסטטיסטיים והחישוביים, ולאפשר השוואה בין ממצאים כמותיים לבין תובנות לשוניות ותמטיות שמפיק מודל שפה.

לצורך הניתוח חולק הקורפוס לשלוש תקופות כרונולוגיות: תקופה מוקדמת, הכוללת שירים עד שנת 1979; תקופת ביניים, הכוללת שירים מהשנים 1988–2002; ותקופה מאוחרת, הכוללת שירים משנת 2007 ואילך. מתוך כל תקופה נבחרו באופן אקראי חמישה שירים, תוך שימוש ב־`random_state=42`, כדי לאפשר שחזור של הדגימה.


עבור כל אחת מן התקופות נוצר קובץ טקסט נפרד הכולל את מילות השירים שנבחרו, לצד שם השיר ושנת הפרסום. לאחר יצירתם, הקבצים שימשו כקלט לניתוח איכותני באמצעות מודל שפה גדול (LLM). במסגרת הניתוח התבקש המודל לתאר את סגנון הכתיבה של כל תקופה מבחינת אוצר המילים, הנושאים המרכזיים, הטון הרגשי והמאפיינים הפואטיים.

התוצרים האיכותניים של מודל השפה שימשו בהמשך להשוואה עם תוצאות הניתוחים הכמותיים, כגון מידול הנושאי (Topic Modeling), ה־`embeddings` וניתוח האשכולות (Clustering). מטרת ההשוואה הייתה לבחון האם התובנות הפרשניות שעלו מן הניתוח האיכותני עולות בקנה אחד עם הדפוסים שהתגלו באמצעות השיטות החישוביות השונות.

תוצאות המסווגים

לצורך בחינת היכולת להבחין בין שלוש תקופות הקריירה של שלמה ארצי על בסיס המאפיינים הסטילומטריים, נבחנו ארבעה מסווגים: Logistic Regression, SVM, Random Forest ו-k-NN. ביצועי המסווגים הוערכו באמצעות Stratified 5-Fold Cross Validation כאשר מדד ההערכה המרכזי היה Accuracy. בנוסף, עבור Logistic Regression, SVM ו-k-NN נבחנו שלוש תצורות שונות של מאפיינים: כלל המאפיינים הסטילומטריים, מאפיינים לקסיקליים בלבד ומאפיינים תחביריים בלבד. עבור Random Forest נבחנה תצורה אחת בלבד, המבוססת על כלל המאפיינים הסטילומטריים.

איור 3 : השוואת ביצועי המסווגים לפי קבוצות המאפיינים



*ר' נספח ב' המפרט את אחוזי הדיוק וסטיית התקן לכל מסווג

ניתן לראות כי שני המסווגים שהציגו את הביצועים הטובים ביותר היו **Random Forest** ו-**SVM** עם דיוק ממוצע של 62.98% ו-62.92% בהתאמה. אחריהם דורג **Logistic Regression**, עם דיוק ממוצע של 59.32%, בעוד שמסווג **k-NN** הציג את הביצועים הנמוכים ביותר, עם דיוק ממוצע של 44.21%.

השוואה בין קבוצות המאפיינים השונות מראה כי עבור כל המסווגים שנבחנו, השימוש בכלל המאפיינים הסטילומטריים הניב את הביצועים הטובים ביותר. כאשר נעשה שימוש במאפיינים לקסיקליים בלבד או במאפיינים תחביריים בלבד, נרשמה ירידה ברמת הדיוק. ממצא זה מצביע על כך שהשילוב בין סוגי המאפיינים השונים מספק ייצוג עשיר ומקיף יותר של סגנון הכתיבה, ומאפשר הבחנה טובה יותר בין תקופות הכתיבה.

בסך הכול, תוצאות המסווגים מצביעות על כך **שקיימים הבדלים סגנוניים הניתנים לזיהוי בין תקופות הקריירה של שלמה ארצי**. אף שהדיוק שהושג אינו מושלם, הביצועים גבוהים באופן משמעותי מרמת ניחוש אקראי, העומדת על כ־33% במקרה של שלוש מחלקות, ומעידים כי המאפיינים הסטילומטריים שנבחרו אכן לוכדים מידע המאפשר להבחין בין תקופות שונות בהתפתחות סגנון הכתיבה של שלמה ארצי.

תוצאות – ניתוח סטילומטרי

מאפיינים מבחינים :

כדי לזהות אילו מאפיינים סטילומטריים תרמו ביותר להבחנה בין תקופות הכתיבה של שלמה ארצי, נבחנו מקדמי המאפיינים במסווג Logistic Regression וחשיבות המאפיינים שחושבה באמצעות Random Forest. ככל שערך המקדם או החשיבות גבוה יותר, כך תרומת המאפיין להבחנה בין התקופות גדולה יותר.

איור 4 : המאפיינים המובילים לפי Logistic Regression

מקדם	מאפיין	דירוג
0.7236	גודל אוצר המילים	1
0.4276	שיעורי תואר הפועל	2
0.4229	MTLD	3
0.3978	אורך שורה ממוצע	4
0.3632	TTR	5
0.3568	אורך מילה ממוצע	6
0.3529	שיעור הפעלים	7
0.3049	שיעור מילות החיבור המתאמות	8
0.2936	מספר הבתים	9
0.2804	שיעור שמות התואר	10

איור 5 : המאפיינים המובילים לפי Random Forest

חשיבות	מאפיין	דירוג
0.0939	MTLD	1
0.0842	יחס פעלים לשמות עצם	2
0.0817	אורך שורה ממוצע	3
0.0646	שיעור הפעלים	4
0.0611	TTR	5
0.0582	שיעור שמות העצם	6
0.0563	גודל אוצר המילים	7
0.558	שיעור שמות התואר	8
0.0523	אורך מילה ממוצע	9
0.0494	שיעור תוארי הפועל	10

מהתבוננות בטבלאות ניתן לראות כי שני המסווגים זיהו מספר מאפיינים משותפים כבעלי תרומה משמעותית להבחנה בין תקופות הכתיבה. בין המאפיינים שחזרו בשני המודלים ניתן למנות את MTLD, TTR, גודל אוצר המילים, אורך השורה הממוצע, אורך המילה הממוצע ושיעור הפעלים. החזרה של אותם מאפיינים בשני מסווגים שונים מחזקת את מהימנות הממצאים ומעידה כי תרומתם אינה תלויה במודל מסוים בלבד.

בנוסף, ניתן להבחין בהבדל מסוים בין שני המסווגים. בעוד שב-Logistic Regression בלטו בעיקר מאפיינים הקשורים לעושר הלקסיקלי, כגון גודל אוצר המילים, MTLD ו-TTR, מסווג Random Forest מעניק חשיבות גבוהה גם למאפיינים תחביריים, ובהם יחס הפעלים לשמות עצם ושיעור הפעלים. ממצא זה מצביע על כך שההבחנה בין תקופות הכתיבה נשענת הן על מאפיינים לקסיקליים והן על מאפיינים תחביריים ומבניים.


בסך הכול, התוצאות מחזקות את המסקנה כי סגנון הכתיבה של שלמה ארצי התפתח לאורך השנים במספר היבטים שונים, וכי שילוב של מאפיינים סטילומטריים מאפשר להבחין בצורה טובה יותר בין תקופות הקריירה שלו.

המרחב הסטילומטרי :

לאחר חילוץ כלל המאפיינים הסטילומטריים עבור כל שיר (כגון TTR, MTLD, אורך מילה ממוצע, שיעור הפעלים, שיעור שמות העצם ומאפיינים נוספים), בוצעה הפחתת ממדים באמצעות PCA לצורך המחשה ויזואלית של מבנה הקורפוס במרחב הסטילומטרי. כל נקודה מייצגת שיר אחד, כאשר המרחק בין נקודות משקף את מידת הדמיון בין סגנונות הכתיבה.


איור 6 : פיזור השירים במרחב הסטילומטרי לפי שנת הפרסום

איור 6 מציג את השירים כאשר צבע כל נקודה מייצג את שנת פרסומה. ניתן לראות כי קיימת נטייה למעבר הדרגתי של צבעי הנקודות לאורך המרחב, דבר המעיד כי גם המאפיינים הסטילומטריים משתנים בהדרגה לאורך הקריירה של שלמה ארצי. עם זאת, המעבר אינו חד, וקיימת חפיפה בין תקופות סמוכות, דבר התואם את ההנחה שהתפתחות סגנונו הייתה רציפה ולא התרחשה בנקודת זמן אחת.



איור 7 : חלוקה לאשכולות במרחב הסטילומטרי

לצורך בחינת מבנה המרחב הסטילומטרי הופעל גם אלגוריתם K-Means עם שלושה אשכולות. ניתן לראות כי האלגוריתם מצליח לזהות שלוש קבוצות עיקריות של שירים, אם כי קיימת חפיפה מסוימת ביניהן. ממצא זה מצביע על כך שהמאפיינים הסטילומטריים אכן מכילים מידע המאפשר להבחין בין קבוצות שונות של שירים, אך המעבר בין התקופות אינו חד אלא הדרגתי.




הניתוח הוויזואלי מחזק את ממצאי המסווגים ואת ניתוח נקודות המפנה. גם ללא שימוש ישיר בשנת הפרסום, ניתן לזהות מבנה פנימי במרחב המאפיינים הסטילומטריים, המעיד כי סגנון הכתיבה של שלמה ארצי השתנה לאורך השנים באופן הדרגתי.

בסך הכול, ניתוח המאפיינים הסטילומטריים מצביע על כך שהבדלים בעושר הלקסיקלי, במאפיינים התחביריים ובמבנה השירים מאפשרים להבחין בין תקופות שונות ביצירתו של שלמה ארצי, ומהווים בסיס לממצאים שהוצגו בהמשך באמצעות ניתוח נקודות המפנה.

תוצאות – זיהוי נקודות מפנה

לצורך זיהוי שינויים סגנוניים לאורך הקריירה של שלמה ארצי בוצע ניתוח Breakpoint Detection, המבוסס על מדידת הדמיון בין תקופות עוקבות במרחב המאפיינים הסטילומטריים. נקודות שבהן נרשמה ירידה משמעותית במדד הדמיון סומנו כנקודות מפנה אפשריות בהתפתחות סגנון הכתיבה.

איור 8 : ערכי הדמיון בין חלונות זמן עוקבים



*ר' נספח ג' המפרט את ערכי הדמיון לכל שנה

איור 8 מציג את ערכי הדמיון בין חלונות זמן עוקבים לאורך הקריירה של שלמה ארצי. הקו הכתום מייצג את סף הזיהוי, בעוד שנקודות הנמצאות מתחתיו מסומנות כנקודות מפנה.

הניתוח זיהה שתי נקודות מפנה מובהקות: 1979 ו-1984. שתי השנים נמצאו מתחת לסף הזיהוי (0.024) וקיבלו ערך דמיון של 0, ולכן סווגו כנקודות מפנה. לעומת זאת, שאר השנים קיבלו ערכי דמיון גבוהים יותר ולא סווגו כנקודות מפנה (ראוי לציין כי בשנת 1988 ערך הדמיון היה 0.025, מעט מעל סף הזיהוי, ולכן אף שהנקודה אינה נראית בבירור בגרף בשל קרבתה לסף, היא אינה מסווגת כנקודת מפנה).

השוואה בין נקודות המפנה לאבני דרך בקריירה של שלמה ארצי

נקודת המפנה הראשונה, סביב שנת 1979, תואמת את התקופה שבה החל ארצי לעבור שינוי מהותי בסגנון כתיבתו. לאחר שנים של ירידה מסחרית וחיפוש אחר כיוון אמנותי חדש, באו האלבומים 'גבר הולך לאיבוד' (1978) ו-'דרכים' (1979), אשר סימנו מעבר מכתובה שהושפעה משירי ארץ ישראל ומשירי משוררים לכתובה אישית, אינטימית ובוגרת יותר. תקופה זו נחשבת עד היום לאחת מנקודות המפנה המשמעותיות ביותר בקריירה של ארצי.

נקודת המפנה השנייה, סביב שנת 1984, מעידה על המשך תהליך השינוי. בשנה זו יצא האלבום 'תרקוד', שנוצר במסגרת שיתוף הפעולה עם המפיק לואי להב – שיתוף פעולה זה נחשב לאחד הגורמים המרכזיים שעיצבו את סגנונו המוזיקלי בשנים שלאחר מכן. בתקופה זו התגבש סגנון הפופ־רוק המזוהה עמו, והכתובה הפכה אישית, ישירה ומורכבת יותר. העובדה שהשיטות החישוביות זיהו שינוי דווקא בתקופה זו מעידה כי ההתפתחות האמנותית של ארצי באה לידי ביטוי גם במאפיינים הלשוניים והסטילומטריים של שיריו.

יש לציין כי בשנת 1988 התקבל ערך דמיון של 0.025, גבוה במעט בלבד מסף הזיהוי (0.024), ולכן השנה לא סווגה כנקודת מפנה. עם זאת, העובדה שמדובר בתקופה שבה יצא האלבום חום יולי אוגוסט, הנחשב לאחת מאבני הדרך המרכזיות בקריירה של שלמה ארצי, מחזקת את הפרשנות כי האלגוריתם זיהה את תחילתו של תהליך השינוי בשנת 1984. בהתאם לכך, שנת 1988 אינה מייצגת נקודת מפנה חדשה, אלא שלב שבו השינוי הסגנוני שכבר החל הגיע לכדי הבשלה.

אחד הממצאים החשובים ביותר במחקר הוא ההתאמה בין נקודות המפנה שזוהו באופן חישובי לבין אבני הדרך המוכרות בקריירה של שלמה ארצי. נקודות המפנה לא נקבעו מראש על סמך ידע ביוגרפי או מוזיקלי, אלא זוהו באופן אוטומטי מתוך ניתוח המאפיינים הסטילומטריים של השירים בלבד. העובדה שהניתוח החישובי הוביל לזיהוי תקופות התואמות אבני דרך מוכרות בהתפתחותו האמנותית של שלמה ארצי מחזקת את השערת המחקר ומעידה כי ניתן לזהות שינויים סגנוניים משמעותיים באמצעות כלים מתחום עיבוד השפה הטבעית.

תוצאות – Topic Modeling

לצורך זיהוי התמות המרכזיות ביצירתו של שלמה ארצי הופעל מודל LDA (Latent Dirichlet Allocation) עם 10 נושאים. בסיום האימון זוהו עשר קבוצות מילים בעלות נטייה להופיע יחד בשירים שונים. כל קבוצה מייצגת נושא מרכזי ביצירתו של ארצי ומאפשרת לבחון את התמות החוזרות בקורפוס. טבלה 9 מציגה את עשרת הנושאים שזוהו באמצעות מודל ה-LDA, את המילים המרכזיות בכל נושא ואת הפרשנות שניתנה לו.

איור 9 : טבלת הנושאים

נושא	מילים מרכזיות	פרשנות
0	יפה, אהבה, אוהבת, הזמן	אהבה ויחסים
1	היינו, קיץ, דברים, ואולי	זיכרונות ונוסטלגיה
2	בים, מול, מביטים, כולם	טבע ונוף
3	בשקט, הדרך, יודע, בי	התבוננות פנימית
4	חיים, האיש, בואי, תמיד	חיים וזוגיות
5	פתאום, השיר, הים, הסתיו	שינוי וגעגוע
6	אהבה, החלום, ימים	אהבה ותקווה
7	אוהב, לבד, החברים	קשרים חברתיים ובדידות
8	בדרך, מכאן, הרחק, מחר	מסע ודרך
9	ילד, מילים, בסתיו	ילדות וזיכרון

פרשנות

ניתוח הנושאים מראה כי יצירתו של שלמה ארצי עוסקת במגוון תמות מרכזיות, ובהן אהבה, זוגיות, געגוע, זיכרון, נוסטלגיה, מסע, התבוננות פנימית וטבע.

ניתן לראות כי חלק מן התמות מופיעות ביותר מנושא אחד. לדוגמה, אהבה מופיעה בנושאים 0 ו-6, ואילו זיכרון ונוסטלגיה מופיעים בנושאים 1 ו-9. ממצא זה מעיד כי תמות אלו מהוות מרכיב מרכזי ביצירתו של ארצי. בנוסף, זוהו נושאים העוסקים במסע (נושא 8), בהתבוננות פנימית (נושא 3) ובקשרים חברתיים (נושא 7), המעידים על שילוב בין חוויות אישיות לבין התבוננות במציאות.


בסך הכול, תוצאות ה-Topic Modeling מצביעות על קיומן של תמות מרכזיות החוזרות לאורך הקורפוס, ובהן אהבה, זוגיות, זיכרון, נוסטלגיה, מסע והתבוננות פנימית. תמות אלו מספקות תמונה של עולמות התוכן המרכזיים המאפיינים את יצירתו של שלמה ארצי לאורך השנים.

תוצאות – Embeddings & Clustering

לאחר יצירת ה־Embeddings עבור כלל שירי הקורפוס באמצעות מודל DictaBERT, בוצע ניתוח Clustering באמצעות האלגוריתם K-Means עם שלושה אשכולות ($k=3$). בנוסף, בוצעה הפחתת ממדים באמצעות PCA לצורך המחשה ויזואלית של מבנה הקורפוס.


איור 10: פיזור השירים במרחב PCA לאחר חלוקה לשלושה אשכולות באמצעות K-Means
איור 10 מציג את פיזור השירים במרחב PCA לאחר חלוקה לשלושה אשכולות באמצעות K-Means. כל נקודה מייצגת שיר, והצבע מציין את האשכול שאליו הוא שויך.

ניתן לראות כי האלגוריתם זיהה שלוש קבוצות מובחנות במרחב הייצוגים הסמנטיים. אף שקיימת חפיפה מסוימת בין חלק מן האשכולות, ניכרת הפרדה ברורה ביניהם, דבר המעיד כי ה־Embeddings מצליחים ללכוד הבדלים סמנטיים בין שירים מתקופות שונות.



איור 11 : פיזור השירים במרחב PCA כאשר הצבע מייצג את שנת הפרסום

איור 11 מציג את אותם השירים במרחב PCA, כאשר צבע כל נקודה מייצג את שנת הפרסום. ניתן לראות מעבר הדרגתי בצבעים לאורך המרחב, המעיד על שינוי סמנטי מתמשך לאורך הקריירה של ארצי.



איור 12 : התפלגות השירים לפי תקופה בכל אשכול

Late	Middle	Early	Cluster
1	1	15	0
17	7	19	1
38	53	16	2

מהתפלגות השירים בין האשכולות עולה כי קיימת הבחנה בין תקופות שונות בקריירה של ארצי. Cluster 0 כולל בעיקר שירים מן התקופה המוקדמת, Cluster 1 כולל בעיקר שירים מן התקופה המאוחרת, ואילו Cluster 2 מורכב ברובו משירים מתקופת הביניים.

הממצאים מצביעים על כך שהמודל מצליח לזהות קבוצות של שירים בעלי מאפיינים סמנטיים דומים, גם ללא שימוש במידע כרונולוגי במהלך תהליך האשכולות.

בנוסף, ניתן לראות כי מרבית השירים מתקופת הביניים ומהתקופה המאוחרת מרוכזים באותו אשכול מרכזי. עובדה זו עשויה להעיד כי השינוי המשמעותי ביותר בקריירה של ארצי התרחש בין התקופה המוקדמת לבין התקופות המאוחרות יותר, בעוד שההבדלים בין תקופת הביניים לתקופה המאוחרת מתונים יותר.

קיומו של אשכול ביניים מעורב מצביע על כך שהמעבר הסגנוני לא התרחש בנקודת זמן חדה אחת, אלא היה תהליך הדרגתי שבו מאפיינים מתקופות שונות התקיימו במקביל לאורך השנים.

בסך הכול, תוצאות ניתוח ה־Embeddings וה־Clustering מצביעות על כך שהייצוגים הסמנטיים מצליחים ללכוד הבדלים בין שירים מתקופות שונות. אף שההפרדה אינה מוחלטת, ניכרת מגמת מעבר הדרגתית לאורך הקריירה של שלמה ארצי, התואמת את ההתפתחות הסגנונית שנמצאה גם בשיטות הניתוח האחרות.

תוצאות - השוואות AI לשיטות קלאסיות

בנוסף לשיטות החישוביות שנבחנו במחקר, בוצע ניתוח איכותני באמצעות מודל שפה גדול (GPT), במטרה לבחון האם ניתן לזהות באמצעותו הבדלים בין תקופות שונות בקריירה של שלמה ארצי ולהשוות את ממצאיו לתוצאות שהתקבלו בשיטות הכמותיות. לצורך הניתוח נבחרו חמישה שירים מייצגים מכל אחת משלוש התקופות שנבחנו במחקר: התקופה המוקדמת (1970–1979), תקופת הביניים (1988–2002) והתקופה המאוחרת (2007–2025). מודל השפה התבקש לנתח את אוצר המילים, הנושאים המרכזיים, הטון הרגשי והמאפיינים הפואטיים של כל תקופה.

באופן כללי, הניתוח האיכותני הצביע על מעבר הדרגתי בין תקופות הקריירה. התקופה המוקדמת אופיינה בשפה לירית ורומנטית יותר, תקופת הביניים בשפה יומיומית ומציאותית יותר, ואילו התקופה המאוחרת התאפיינה בשפה אישית וישירה יותר, לצד עיסוק מוגבר בזיכרון, במשפחה, במשמעות החיים ובזהות האישית.

איור 13 : השוואת ממצאי ה-AI לשיטות החישוביות

שיטה	ממצא מרכזי	ממצאי ה-AI
Stylometry	הבדלים בין תקופות הכתיבה על בסיס מאפיינים לשוניים	שינוי הדרגתי בסגנון, בטון הרגשי ובאוצר המילים בין התקופות
Topic Modeling (LDA)	תמות מרכזיות החוזרות לאורך הקורפוס	נושאים דומים, ביניהם אהבה, זיכרון, יחסים בין-אישיים והתבוננות פנימית
Embeddings & Clustering	הפרדה בין קבוצות שירים מתקופות שונות	הבדלים בין התקופות ותיאר מעבר ברור בהתפתחות הסגנון
Breakpoint Detection	נקודות מפנה לאורך הקריירה	שינוי הדרגתי בין התקופות, אך אינו מיועד לזיהוי מדויק של נקודות מפנה

ניתן לראות כי קיימת התאמה כללית בין ממצאי הניתוח האיכותני לבין תוצאות השיטות החישוביות. בעוד שהשיטות הקלאסיות מספקות מדדים כמותיים לזיהוי שינויים סגנוניים, מודל השפה מוסיף רובד פרשני המסייע להבין את אופיים של אותם שינויים ואת המשמעויות העולות מן הטקסטים.

בסך הכול, **השילוב בין השיטות הכמותיות לבין הניתוח האיכותני מספק תמונה מקיפה יותר של התפתחות סגנון הכתיבה של שלמה ארצי**. השיטות החישוביות מאפשרות לזהות ולמדוד את השינויים באופן אובייקטיבי, ואילו מודל השפה מסייע בפרשנותם ובהבנת ההבדלים בין התקופות.

דיון ומסקנות

מטרת המחקר הייתה לבחון האם ניתן לזהות שינויים סגנוניים לאורך הקריירה של שלמה ארצי באמצעות כלים מתחום עיבוד השפה הטבעית. ממצאי המחקר מצביעים על כך ששילוב של מספר שיטות חישוביות מאפשר לזהות הבדלים בין תקופות שונות ביצירתו של שלמה ארצי ולספק תמונה עקבית של התפתחות סגנונו לאורך השנים.

כל אחת מן השיטות שנבחנו תרמה זווית הסתכלות שונה על הקורפוס. הניתוח הסטילומטרי בחן מאפיינים לשוניים, מודל ה־Topic Modeling זיהה תמות מרכזיות, הייצוגים הסמנטיים וניתוח האשכולות הצביעו על דמיון והבדלים בין השירים, והניתוח האיכותני באמצעות GPT סיפק פרשנות לתהליכים שהתגלו באמצעים הכמותיים. השילוב בין השיטות אפשר לקבל תמונה רחבה ומעמיקה יותר מאשר שימוש בכל אחת מהן בנפרד.

אחד הממצאים המרכזיים של המחקר הוא ההתאמה בין נקודות המפנה שזוהו באופן חישובי לבין אבני הדרך המרכזיות בקריירה של שלמה ארצי, כפי שהוצג בפרק תוצאות זיהוי נקודות המפנה. העובדה שהניתוח זיהה באופן עצמאי תקופות התואמות שינויים אמנותיים מוכרים מחזקת את השערת המחקר ומעידה כי השינויים שהתגלו אינם תוצאה של חלוקה כרונולוגית בלבד, אלא משקפים שינויים ממשיים בסגנון הכתיבה. ממצא זה מדגים את יכולתן של שיטות לעיבוד שפה טבעית לזהות תהליכי התפתחות אמנותיים מתוך הטקסט עצמו, ללא הסתמכות על מידע ביוגרפי מוקדם.

לצד הממצאים, למחקר מספר מגבלות. הקורפוס כלל מספר מוגבל של שירים והתבסס על חלוקה מוגדרת מראש לתקופות, אשר ייתכן כי אינה היחידה האפשרית. בנוסף, חלק מן הניתוחים, ובפרט הניתוח האיכותני, כוללים מרכיב פרשני ולכן עשויים להיות מושפעים מאופן הניתוח.

למרות מגבלות אלו, ממצאי המחקר מצביעים על כך **ששילוב בין שיטות מסורתיות לעיבוד שפה טבעית לבין מודלי שפה מתקדמים מאפשר לזהות שינויים סגנוניים משמעותיים לאורך הקריירה של יוצר**. גישה זו עשויה לשמש בסיס למחקרים עתידיים על יוצרים נוספים ולהרחבת הניתוח באמצעות קורפוסים גדולים יותר ושיטות מתקדמות נוספות לעיבוד טקסט.

עבודות המשך

מחקר זה מהווה בסיס להמשך חקר התפתחות סגנון הכתיבה של שלמה ארצי באמצעות כלים מתחום עיבוד השפה הטבעית, ומעלה מספר כיווני מחקר אפשריים.

ראשית, ניתן להרחיב את הקורפוס כך שיכלול שירים נוספים, גרסאות שונות של שירים, הופעות חיות ויצירות שלא נכללו במחקר הנוכחי. הרחבת הקורפוס עשויה לאפשר ניתוח מקיף ומדויק יותר של התפתחות סגנונו של היוצר.

שנית, ניתן להרחיב את המחקר ליוצרים ישראלים נוספים, כגון שלום חנוך, אהוד בנאי או יהונתן גפן, ולהשוות בין דפוסי ההתפתחות הסגנונית של יוצרים שונים, במטרה לבחון האם קיימים מאפיינים משותפים או ייחודיים לכל יוצר.

בנוסף, ניתן לבחון מודלי שפה עבריים מתקדמים יותר ושיטות Embedding נוספות, במטרה לשפר את איכות ייצוג הטקסטים ואת היכולת לזהות שינויים סגנוניים לאורך זמן.

כיוון מחקר נוסף הוא שילוב מאפיינים מוזיקליים לצד מילות השירים, כגון קצב, סולם, עיבוד מוזיקלי ומבנה הלחן. שילוב מידע טקסטואלי ומוזיקלי עשוי לספק תמונה רחבה ומעמיקה יותר של התפתחות סגנונו האמנותי של היוצר.

בנוסף, ניתן להרחיב את הגישה שהוצגה במחקר זה לניתוח יצירתם של סופרים, משוררים ויוצרים נוספים, ובכך לבחון את יכולתן של שיטות עיבוד שפה טבעית לזהות תהליכי שינוי והתפתחות סגנונית ביצירות מסוגים שונים.

לבסוף, ניתן לבחון אלגוריתמים נוספים לזיהוי נקודות מפנה (Change Point Detection) ולהשוות את ביצועיהם לאלו שנבחנו במחקר הנוכחי. השוואה כזו עשויה לשפר את היכולת לזהות שינויים סגנוניים באופן מדויק יותר, לאפיין את מועד התרחשותם ולתרום להבנת תהליך ההתפתחות הסגנונית לאורך זמן.

נספח א' : כלל השירים עליהם הפרויקט התבסס -

album	year	title	song_id
אותיות נחמה	2025	אותיות נחמה	1
		משמעות לחלומותיי	2
		כשהכל יתבהר	3
		היה לי אותך	4
		פעם פם פם	5
		הפנים היפות	6
		מישהו חושב עליך	7
		לטרוף את החיים	8
		תני לי יד בעולם	9
		עזור לי	10
		פעם טעים ופעם מר	11
		ליד הים	12
		שקט עכשיו בחדר	13
		השיר החסר	14
		שווה שוב להתחיל	15
קצפת	2016	ואולי	16
		עוד אחד ודי	17
		לנצח יחד	18
		ביתנו	19
		כמעט	20
		בסתיו	21
		מחמל נפשי	22
		פעם אחת בחודש	23
		קצפת	24
		איך מרגישים כשיש אהבה	25
		עלייך לא אוותר	26
		והאמת	27
		הכינורות	28
		גבעה אחת	29
אושר אקספרס	2012	חוזרים הביתה	30
		כל יום	31
		לתת ולקחת	32
		נדבר מהלב	33
		אלוהיי	34

		לא מוותר על החלום שלי	35
		אומץ	36
		פלורידה	37
		מת להגיד לך	38
		קיץ בארץ לו	39
		אושר אקספרס	40
		שלא יעלמו הדברים היפים	41
שפויים	2007	תתארו לכם	42
		האמיתי	43
		איסלנד	44
		נצמדנו	45
		לעזאזל איך לא ידעתי	46
		מתנה ליום הולדת	47
		החיים	48
		הבחורה שלי	49
		תוכיחי לי	50
		ברגע האחרון	51
		דמעות שחורות	52
		הילוך חוזר	53
		שפויים	54
		לעולמים	55
		הרחק מכאן	56
צימאון	2002	פה ושם	57
		בשקט בשקט	58
		דבר איתי על המצב	59
		על פי תנועת הרכבות	60
		להציל אותך	61
		שיר הקירבה	62
		כל אחד והסיפור שלו	63
		בדרך	64
		געגועי	65
		עשרים וארבע שעות	66
		הבית שלך	67
		פצצת אטום בשמים	68
		הו לעזאזל	69
		צימאון	70
		לא לקחתי ללב	71
שניים	1996	האהבה הישנה	72
		לאן, לאן, לאן	73

		סיפור רומנטי	74
		אוטובוס מס' 1	75
		זיכרון ורוד	76
		מנגב לך את הדמעות	77
		זה מה שנשאר	78
		שיר על כל השאיפות	79
		מגע אנושי	80
		הייתי והיינו	81
		שניים	82
		ניקח לנו יום	83
		היא לא יודעת מה עובר עלי	84
		שישה	85
		דו"ח רצח	86
		צרות בת"א	87
		אבסורד	88
		אור בקצה המנהרה	89
		ריקוד סוף המאה	90
ירח	1992	לאהבה Love	91
		כמו אז	92
		קצת משונה שלא נשאר	93
		שאלתי מה קרה	94
		תגידי	95
		הסכין, הרובה והאבן	96
		מביטים בים	97
		אני בא	98
		אחרת אתה מת	99
		ואלס בחמש ושלושים	100
		פעם תורי ופעם תורך	101
		ערב בלי ירח	102
חום יולי אוגוסט	1988	ארץ חדשה	103
		טלפני, טלפני	104
		עבד הממהר	105
		חום יולי אוגוסט	106
		באיזשהו מקום	107
		לב שבור לרסיסים	108
		היית איתי הרי	109
		בגרמניה לפני המלחמה	110
		אני כבר מצטער	111
		רומניה	112

		נבראתי לך	113
		תחת שמי ים התיכון	114
		ימים כאלה	115
		או שזה הזמן	116
		כמו חצר גדולה	117
תרקוד	1984	תרקוד	118
		לא לזמן ממושך	119
		צריך להתקדם	120
		וביחד נזדקן	121
		בקומת הגג שלך	122
		רוב הזמן את אישתי	123
		איזו התחלה	124
		מה רצינו להגיד	125
		ועכשיו לנוע	126
דרכים	1979	אף פעם לא תדעי	127
		צוותא	128
		אחרי הכל את שיר	129
		אתמול חלפו הציפורים	130
		שינויי מזג האוויר	131
		פתאום כשלא באת	132
		שיר חייל	133
		עפיפונים	134
גבר הולך לאיבוד	1978	גבר הולך לאיבוד	135
		רק עלה	136
		את מספרת	137
		אל תוך העיר	138
		האיש ההוא	139
		את אינך יודעת	140
		בלילות אני מתגעגע	141
		כמו ציפור	142
את ואני	1975	את ואני	143
		את הלכת	144
		עכשיו את מבוגרת להבין	145
		שיר אהבה אחרון	146
		הריקוד האחרון של 1956	147
		היי ליזה	148
		פעם אהבתי אותך	149
		אליל העשרה	150
		דברים	151

		מתחת למיטה	152
משחקי 26	1975	יוסי בן עשרים ושש	153
		שיר התנועה	154
		מנגן ושר	155
		החברים הישנים	156
		בואו נשחק משחק	157
		הבלדה על אפרים	158
		שיר אהבה	159
		המציל	160
		המזדנבות	161
		שיר על ילד מפורסם	162
		עזרא ובוקובזה	163
		משחקי 26	164
שלמה ארצי	1970	מרקו	165
		האם עודך יפה	166
		רק זיכרון אחד	167
		זה העולם	168
		הנסיעה הנפלאה	169
		אהבתיה	170
		האם השלישית	171
		אנחנו לא צריכים	172
		נחלים	173
		תפילת ערבית	174
		שיר קיץ	175
		הבלדה על לבן בן בתואל	176

נספח ב' : אחוזי הדיוק וסטיית התקן מתוצאות מתוצאות ביצועי המסווגים -

מסווג	קבוצת מאפיינים	דיוק ממוצע	סטיית תקן
Logistic Regression	כלל המאפיינים	59.32%	10.05%
	מאפיינים לקסיקליים	50.96%	9.41%
	מאפיינים תחביריים	47.88%	4.25%
SVM	כלל המאפיינים	62.92%	4.82%
	מאפיינים לקסיקליים	53.32%	7.04%
	מאפיינים תחביריים	47.33%	3.67%
k-NN	כלל המאפיינים	44.21%	7.45%
	מאפיינים לקסיקליים	43.71%	4.75%
	מאפיינים תחביריים	35.26%	7.59%
Random Forest	כלל המאפיינים	62.98%	9.17%

נספח ג' : ערכי הדמיון עבור כל נקודת זמן -

שנה	ערך הדמיון
1978	0.540
1979	0.000
1984	0.000
1988	0.025
1992	0.171
1996	0.140
2002	0.310
2007	0.129
2012	0.232
2016	0.426